

Laporan Teknis Komprehensif

Coding Camp 2026 powered by DBS Foundation

ID Tim Capstone Project : CC26-PSU238

Tema Capstone : Healthy Lives & Well-being

Nama/Judul Proyek : GiSee (Gain Insight, See Your Nutrition)

List Anggota :

1. (CDCC014D6Y2108) - (I Putu Satria Dharma Wibawa) - (Data Scientist) - **[Aktif]**
2. (CDCC014D6Y1806) - (I Putu Agus Wahyu Wirakusuma Putra) - (Data Scientist) - **[Aktif]**
3. (CFCC014D6Y1969) - (Anak Agung Yoga Aditya Putra) - (Full-Stack Web Developer) - **[Aktif]**
4. (CFCC014D6Y1548) - (Anak Agung Bagus Yoga Udiana) - (Full-Stack Web Developer) - **[Aktif]**
5. (CACC005D6Y0971) - (Kevin Arjuna Steffers) - (AI Engineer) - **[Aktif]**
6. (CACC009D6Y2637) - (Raffael Fidhera Yahya) - (AI Engineer) - **[Aktif]**

Tautan:

1. Link File Analisis Data :

https://drive.google.com/drive/folders/1o2cPWx5MYB1pdAP0xNDA9-J-rQ5cg4__?usp=drive_link

2. Link Data Nutrisi :

<https://drive.google.com/drive/folders/15ljQ3avCbWUhPhbV3MFOcIsQL7y07K12>

3. Link Dashboard Streamlit : <https://giseedata.streamlit.app/>

BAB I

PROBLEM DISCOVERY & BUSINESS INSIGHTS

1.1 Latar Belakang dan Pernyataan Masalah

Permasalahan utama yang melatarbelakangi pengembangan GiSee adalah rendahnya kesadaran masyarakat terhadap kandungan nutrisi makanan yang dikonsumsi sehari-hari. Sebagian besar masyarakat cenderung memilih makanan berdasarkan rasa, harga, dan kemudahan akses tanpa mempertimbangkan nilai gizi yang terkandung di dalamnya. Kondisi ini diperparah dengan keterbatasan informasi nutrisi yang tersedia secara praktis dan mudah dipahami oleh masyarakat umum, sehingga proses pengambilan keputusan terkait konsumsi makanan sering kali tidak didasarkan pada kebutuhan gizi individu.

Data Survei Kesehatan Indonesia (SKI) 2023 menunjukkan bahwa sebanyak 96,7% penduduk Indonesia berusia di atas 5 tahun masih kurang mengonsumsi buah dan sayur sesuai rekomendasi gizi nasional. Mayoritas masyarakat hanya mengonsumsi 1–2 porsi buah dan sayur per hari, jauh di bawah anjuran minimal lima porsi per hari. Kondisi ini menunjukkan masih rendahnya pemahaman dan perhatian masyarakat terhadap kualitas asupan nutrisi yang dikonsumsi setiap hari.

Di sisi lain, Indonesia masih menghadapi berbagai permasalahan gizi yang kompleks. Berdasarkan hasil Survei Status Gizi Indonesia (SSGI) 2024, prevalensi stunting nasional masih berada pada angka 19,8%, yang menunjukkan bahwa hampir satu dari lima balita di Indonesia mengalami gangguan pertumbuhan akibat masalah gizi kronis. Meskipun angka tersebut mengalami penurunan dibandingkan tahun sebelumnya, kondisi ini tetap menjadi tantangan besar dalam pembangunan kesehatan masyarakat.

Hasil identifikasi kebutuhan pengguna menunjukkan bahwa salah satu penyebab utama rendahnya kesadaran gizi adalah sulitnya masyarakat memperoleh informasi nutrisi makanan secara cepat dan akurat. Sebagian besar aplikasi kesehatan yang tersedia mengharuskan pengguna melakukan pencatatan makanan secara manual, yang sering dianggap merepotkan dan

memerlukan pengetahuan mengenai jenis serta jumlah makanan yang dikonsumsi. Akibatnya, banyak pengguna tidak melakukan pemantauan asupan makanan secara konsisten sehingga sulit mengontrol konsumsi kalori maupun makronutrien harian.

Perkembangan teknologi *Artificial Intelligence*, khususnya *Computer Vision* dan *Deep Learning*, membuka peluang untuk mengatasi permasalahan tersebut melalui sistem pengenalan makanan berbasis citra. Dengan memanfaatkan teknologi ini, proses identifikasi makanan dapat dilakukan secara otomatis melalui foto makanan yang diunggah pengguna. Hasil identifikasi kemudian dapat diintegrasikan dengan basis data nutrisi untuk menghasilkan estimasi kandungan kalori, protein, lemak, dan karbohidrat secara cepat. Pendekatan ini berpotensi mengurangi hambatan dalam proses pencatatan makanan serta meningkatkan kesadaran masyarakat terhadap pola konsumsi yang lebih sehat.

Berdasarkan permasalahan tersebut, diperlukan pengembangan sistem cerdas yang tidak hanya mampu mengenali jenis makanan dari gambar, tetapi juga memberikan informasi nutrisi yang mudah dipahami, melakukan pencatatan konsumsi harian, serta memberikan insight personal terkait pola makan pengguna. Oleh karena itu, proyek GiSee dikembangkan sebagai solusi berbasis AI yang mengintegrasikan teknologi rekognisi makanan, perhitungan nutrisi personal, dan analisis pola konsumsi untuk membantu masyarakat menerapkan gaya hidup yang lebih sehat dan terukur.

1.2 Pertanyaan Bisnis (Business Questions)

Untuk memberikan arah analisis data yang objektif dan memastikan bahwa solusi yang dibangun didasarkan pada karakteristik pangan yang valid, proyek ini merumuskan lima pertanyaan bisnis.

1. Makanan apa yang memiliki kandungan protein tertinggi dalam dataset?
2. Makanan (*dish*) apa yang memiliki rasio protein terhadap kalori paling tinggi sebagai indikator efisiensi sumber protein?
3. Makanan apa yang memiliki kepadatan energi tertinggi berdasarkan jumlah kalori per gram makanan?

4. Zat gizi makro (protein, lemak, atau karbohidrat) mana yang memiliki koefisien korelasi terkuat dalam mempengaruhi total kalori makanan pada dataset?"
5. Apakah terdapat perbedaan profil nutrisi yang signifikan antara kategori makanan *dish* dan *component*?

1.3 Solusi yang Diusulkan

Sebagai jawaban teknis terhadap pernyataan masalah, proyek GiSee mengusulkan sebuah arsitektur solusi berbasis teknologi cerdas dengan pilar utama sebagai berikut.

a) Penerapan Teknologi *Computer Vision*

GiSee memanfaatkan implementasi algoritma *Deep Learning* berbasis *Convolutional Neural Network* (CNN) tingkat lanjut untuk melakukan deteksi objek dan klasifikasi terhadap citra makanan secara real-time. Pengguna cukup mengarahkan kamera ponsel atau mengunggah foto makanan ke dalam sistem untuk memicu proses identifikasi label nama makanan secara otomatis.

b) Pendekatan *Transfer Learning*

Untuk mengoptimalkan efisiensi pelatihan model dan akurasi pengenalan terhadap ragam makanan lokal Indonesia yang memiliki variasi visual tinggi, proyek ini menerapkan metode *Transfer Learning*. Model pra-latih (*pre-trained model*) yang telah memiliki bobot pengetahuan fitur visual makro diekstraksi, kemudian dilakukan proses *fine-tuning* menggunakan pustaka dataset gabungan yang telah dikurasi (Tabel Komposisi Pangan Indonesia dan dataset Kaggle (Indonesian Food and Drink Nutrition Dataset)) untuk membentuk akurasi tinggi pada representasi kuliner nusantara.

c) Pipeline Estimasi Otomatis Kandungan Nutrisi

Hasil luaran (output) berupa label kelas dari model *Computer Vision* akan langsung dilemparkan secara sistematis ke dalam database GiSee yang telah dinormalisasi pada tahap data wrangling (*df_food*). Sistem akan

mengekstraksi nilai energi (Kalori) serta tiga pilar zat gizi makro (Protein, Lemak, Karbohidrat) per porsi acuan secara instan.

BAB II

DATA WRANGLING & PIPELINE STANDARDISASI

2. 1 Data Gathering

Data gathering merupakan tahap awal dalam proses data science yang bertujuan untuk mengumpulkan, mengintegrasikan, dan mempersiapkan data mentah dari berbagai sumber agar dapat digunakan dalam proses analisis dan pengembangan model kecerdasan buatan. Kualitas hasil analisis sangat bergantung pada kualitas data yang diperoleh pada tahap ini. Oleh karena itu, proses ini tidak hanya berfokus pada pengumpulan data dalam jumlah besar, tetapi juga memastikan bahwa data yang diperoleh relevan dengan permasalahan yang ingin diselesaikan.

Dalam proyek GiSee, tahap akuisisi data dilakukan untuk membangun basis data nutrisi makanan Indonesia yang komprehensif. Dataset yang dikumpulkan harus mampu merepresentasikan berbagai jenis makanan lokal maupun modern sehingga dapat digunakan sebagai sumber referensi nutrisi pada sistem *Computer Vision* yang dikembangkan.

Untuk memperoleh cakupan data yang lebih luas dan representatif, proyek ini mengintegrasikan dua sumber dataset yang memiliki karakteristik berbeda namun saling melengkapi.

a) Dataset TKPI (Tabel Komposisi Pangan Indonesia)

Dataset TKPI merupakan sumber data resmi yang diterbitkan oleh Kementerian Kesehatan Republik Indonesia. Dataset ini berisi informasi kandungan gizi berbagai bahan pangan yang umum dikonsumsi masyarakat Indonesia. Keunggulan dataset ini, yaitu:

1. Memiliki kredibilitas tinggi karena berasal dari institusi pemerintah.
2. Menyediakan informasi nutrisi yang terstandarisasi.
3. Mencakup berbagai bahan pangan lokal Indonesia.
4. Menjadi referensi utama dalam bidang gizi dan kesehatan masyarakat.

Namun demikian, sebagian besar data dalam TKPI berfokus pada bahan pangan mentah atau komponen makanan sehingga variasi makanan olahan siap konsumsi masih relatif terbatas.

b) Dataset Kaggle (Indonesian Food and Drink Nutrition Dataset)

Dataset kedua diperoleh dari platform Kaggle yang berisi kumpulan data nutrisi makanan hasil kontribusi komunitas dan berbagai aplikasi pelacak kalori. Keunggulan dataset ini, yaitu:

1. Memiliki variasi makanan yang lebih beragam.
2. Mencakup makanan modern dan produk komersial.
3. Menyediakan berbagai hidangan siap saji yang umum dikonsumsi masyarakat saat ini.
4. Melengkapi kekurangan variasi hidangan pada dataset TKPI.

Dengan menggabungkan kedua sumber tersebut, diperoleh kombinasi data yang mampu merepresentasikan baik bahan pangan dasar maupun makanan olahan siap konsumsi.

Dataset TKPI memiliki jumlah atribut yang jauh lebih banyak karena menyimpan informasi gizi yang lebih rinci, sedangkan dataset Kaggle memiliki struktur yang lebih sederhana namun mencakup variasi makanan yang lebih luas. Perbedaan struktur ini menjadi tantangan utama pada tahap integrasi data karena kedua dataset harus distandarisasi terlebih dahulu sebelum dapat digabungkan ke dalam satu skema data yang seragam.

```
df_tkpi    shape : (1148, 28)    → 1148 baris, 28 kolom  
df_kaggle  shape : (1346, 7)     → 1346 baris, 7 kolom
```

Gambar di atas menunjukkan hasil pemuatan awal kedua dataset ke dalam lingkungan analisis menggunakan Pandas DataFrame. Terlihat bahwa dataset TKPI terdiri atas 1.148 data dengan 28 atribut, sedangkan dataset Kaggle terdiri atas 1.346 data dengan 7 atribut. Perbedaan jumlah atribut ini mengindikasikan adanya perbedaan format penyimpanan data yang memerlukan proses harmonisasi skema pada tahap selanjutnya.

2. 2 Data Assessing

Data assessing merupakan proses evaluasi sistematis terhadap kondisi data mentah sebelum dilakukan proses pembersihan dan transformasi. Tahap ini bertujuan untuk mengidentifikasi berbagai permasalahan yang dapat memengaruhi validitas hasil analisis, seperti kesalahan tipe data, nilai yang hilang (*missing values*), inkonsistensi format, duplikasi data, maupun ketidaksesuaian struktur antar dataset.

Dalam proyek data science, proses ini memiliki peran yang sangat penting karena kualitas model dan insight yang dihasilkan sangat bergantung pada kualitas data yang digunakan. Data yang mengandung kesalahan atau inkonsistensi dapat menghasilkan analisis yang bias, perhitungan statistik yang tidak akurat, bahkan menyebabkan kegagalan pada proses pelatihan model.

Pada proyek GiSee, *data assessing* dilakukan terhadap kedua dataset yang telah berhasil dikumpulkan, yaitu dataset TKPI dan dataset Kaggle. Pemeriksaan dilakukan menggunakan berbagai fungsi eksploratif dari pustaka Pandas untuk memperoleh gambaran menyeluruh mengenai kondisi awal data sebelum memasuki tahap pembersihan (*data cleaning*). Tujuan utama tahap ini adalah untuk mengidentifikasi kesalahan struktur data yang dapat menghambat proses analisis, menemukan nilai yang hilang (*missing values*) pada atribut penting, memastikan setiap variabel memiliki tipe data yang sesuai, menganalisis distribusi awal data untuk memahami karakteristik dataset, dan menyusun strategi pembersihan data berdasarkan temuan yang diperoleh.

a) Pemeriksaan Struktur dan Tipe Data

Tahap pertama dalam audit kualitas data adalah melakukan pemeriksaan terhadap struktur dataset untuk mengetahui jumlah observasi, jumlah atribut, serta tipe data masing-masing kolom.


```

=====
df tkpi - Tipe Data
=====
No                int64
Kode              object
Nama Bahan Makanan  object
Air (g)          object
Energi (Kal)      int64
Protein (g)       object
Lemak (g)        object
Karbohidrat (g)   object
Serat (g)        object
Abu (g)          object
Kalsium/Ca (mg)   object
Fosfor/P (mg)     object
Besi/Fe (mg)      object
Natrium/Na (mg)   object
Kalium/Ka (mg)    object
Tembaga/Cu (mg)   object
Seng/Zn (mg)      object
Retinol/Vit.A (mcg) object
Beta-karoten (mcg) object
Karoten Total (mcg) object
Thiamin/Vit.B1 (mg) object
Riboflavin/Vit.B2 (mg) object
Niasin (mg)       object
Vitamin C (mg)    object
BDD (%)           object
Mentah/Olahan     object
Kelompok Makanan  object
Sumber TKPI 2019   object
dtype: object

=====
df kaggle - Tipe Data
=====
id                int64
calories          float64
proteins          float64
fat              float64
carbohydrate      float64
name             object
image            object
dtype: object

```

Hasil pemeriksaan menunjukkan adanya perbedaan kualitas struktur yang cukup signifikan antara dataset TKPI dan dataset Kaggle. Pada dataset Kaggle, seluruh atribut nutrisi utama seperti kalori (*calories*), protein (*proteins*), lemak (*fat*), dan karbohidrat (*carbohydrate*) telah tersimpan dalam format numerik sehingga dapat langsung digunakan untuk proses perhitungan statistik maupun visualisasi data.

Sebaliknya, pada dataset TKPI ditemukan permasalahan struktur yang cukup krusial. Sebagian besar kolom nutrisi yang seharusnya berisi nilai numerik justru terbaca sebagai tipe data object atau string. Permasalahan ini ditemukan pada hampir seluruh atribut zat gizi makro maupun mikro, termasuk kolom Protein (g), Lemak (g), Karbohidrat (g), Kalsium (mg), Fosfor (mg), Besi (mg), Vitamin A, dan berbagai atribut gizi lainnya.

Permasalahan tersebut terjadi karena format penyimpanan data pada file sumber menggunakan tanda koma (,) sebagai pemisah desimal, sedangkan sistem pembacaan data Python secara default mengharapkan tanda titik (.) sebagai pemisah desimal. Selain itu, ditemukan pula karakter non-numerik seperti tanda strip (-), string kosong, dan beberapa simbol lain yang menyebabkan kolom numerik gagal dikenali sebagai angka.

Kondisi ini menjadi permasalahan yang sangat penting karena kolom bertipe object tidak dapat digunakan untuk melakukan operasi matematika maupun statistik. Akibatnya, proses audit lanjutan seperti perhitungan rata-rata, median, standar deviasi, korelasi, maupun visualisasi distribusi data tidak dapat dilakukan secara akurat.

Oleh karena itu, dilakukan tindakan korektif awal berupa pembersihan karakter pengganggu dan konversi tipe data sebelum proses audit kualitas data dilanjutkan. Langkah ini sebagai penyesuaian teknis agar proses penilaian kualitas data dapat menghasilkan informasi yang valid.

```
=====
df_tkpi - Tipe Data
=====
No                int64
Kode              object
Nama Bahan Makanan  object
Air (g)          float64
Energi (Kal)      int64
Protein (g)       float64
Lemak (g)         float64
Karbohidrat (g)   float64
Serat (g)         float64
Abu (g)           float64
Kalsium/Ca (mg)   float64
Fosfor/P (mg)     float64
Besi/Fe (mg)      float64
Natrium/Na (mg)   float64
Kalium/Ka (mg)    float64
Tembaga/Cu (mg)   float64
Seng/Zn (mg)      float64
Retinol/Vit.A (mcg) float64
Beta-karoten (mcg) float64
Karoten Total (mcg) float64
Thiamin/Vit.B1 (mg) float64
Riboflavin/Vit.B2 (mg) float64
Niasin (mg)       float64
Vitamin C (mg)    float64
BDD (%)           float64
Mentah/Olahan     object
Kelompok Makanan  object
Sumber TKPI 2019   object
dtype: object
```

Setelah karakter non-numerik dibersihkan dan pemisah desimal dinormalisasi, seluruh kolom nutrisi pada dataset TKPI berhasil dikonversi

menjadi tipe data numerik (float64), sehingga kedua dataset memiliki struktur yang konsisten dan siap dievaluasi lebih lanjut.

b) *Analisis Missing Values*

Setelah struktur data berhasil dinormalisasi, langkah berikutnya adalah melakukan identifikasi terhadap nilai yang hilang (*missing values*). Keberadaan missing values merupakan salah satu masalah kualitas data yang paling umum ditemukan dalam proyek data science. Jika tidak ditangani dengan baik, data yang hilang dapat menyebabkan distorsi pada hasil analisis statistik, mengurangi jumlah sampel yang tersedia, bahkan menurunkan performa model.

```
=====
df_tkpi - Missing Values (Kolom Utama)
=====
Nama Bahan Makanan      0
Energi (Kal)             0
Protein (g)             11
Lemak (g)               11
Karbohidrat (g)         65

=====
df_kaggle - Missing Values
=====
Tidak ada missing values.
```

Hasil pemeriksaan menunjukkan bahwa dataset Kaggle berada dalam kondisi yang sangat baik karena tidak ditemukan satupun nilai kosong pada seluruh atribut yang digunakan dalam penelitian. Sebaliknya, dataset TKPI masih mengandung sejumlah nilai kosong pada beberapa kolom nutrisi utama. Kolom Protein (g) dan Lemak (g) masing-masing memiliki 11 data kosong, sedangkan kolom Karbohidrat (g) memiliki 65 data kosong.

Berdasarkan hasil penelusuran terhadap sumber data asli, nilai kosong tersebut bukan disebabkan oleh kesalahan pencatatan, melainkan karena beberapa bahan pangan memang tidak memiliki kandungan zat gizi tertentu

secara alami. Temuan ini menjadi dasar penting dalam menentukan strategi penanganan missing values pada tahap pembersihan data berikutnya.

c) Analisis Duplikasi Data

Pemeriksaan selanjutnya dilakukan untuk mendeteksi keberadaan data duplikat yang dapat menyebabkan bias pada hasil analisis. Duplikasi data berpotensi meningkatkan frekuensi kemunculan suatu objek secara tidak proporsional sehingga menghasilkan nilai rata-rata maupun distribusi yang menyesatkan.

```
df_tkpi    - duplikat baris penuh : 0  
df_kaggle  - duplikat baris penuh : 0
```

Berdasarkan hasil pemeriksaan menggunakan fungsi `.duplicated()`, tidak ditemukan satupun baris data yang terduplikasi secara penuh pada kedua dataset. Baik dataset TKPI maupun dataset Kaggle memiliki nilai duplikasi sebanyak nol baris. Hasil ini menunjukkan bahwa setiap observasi pada kedua dataset bersifat unik jika ditinjau berdasarkan kombinasi seluruh atribut yang dimiliki.

Meskipun demikian, pemeriksaan ini hanya mendeteksi duplikasi sempurna (*exact duplicate*). Potensi duplikasi parsial masih mungkin terjadi pada kolom nama makanan akibat variasi penulisan, penggunaan singkatan, atau kesalahan ketik. Oleh karena itu, pemeriksaan lanjutan menggunakan pendekatan *exact matching* dan *fuzzy matching* tetap diperlukan pada tahap pembersihan data.

d) Analisis Statistik Deskriptif

Setelah struktur data berhasil dinormalisasi dan kualitas dasar dataset dipastikan memadai, dilakukan analisis statistik deskriptif untuk memperoleh gambaran umum mengenai karakteristik nutrisi pada kedua dataset.

```

=====
df_tkpi - Statistik Deskriptif (kolom nutrisi utama)
=====

```

	Energi (Kal)	Protein (g)	Lemak (g)	Karbohidrat (g)
count	1148.00	1137.00	1137.00	1083.00
mean	198.13	9.75	7.45	25.15
std	162.42	11.52	13.74	25.02
min	8.00	0.10	0.00	0.10
25%	73.75	1.80	0.50	5.70
50%	142.00	4.90	2.00	14.30
75%	320.00	14.50	8.20	37.75
max	902.00	74.30	100.00	94.00

```

=====
df_kaggle - Statistik Deskriptif (kolom nutrisi utama)
=====

```

	calories	proteins	fat	carbohydrate
count	1346.00	1346.00	1346.00	1346.00
mean	203.22	10.00	7.58	25.39
std	163.08	11.85	13.73	32.19
min	0.00	0.00	0.00	0.00
25%	75.00	1.80	0.50	4.53
50%	146.00	5.00	2.00	13.30
75%	333.75	15.00	8.28	37.58
max	940.00	83.00	100.00	647.00

Hasil analisis menunjukkan bahwa kedua dataset memiliki pola distribusi yang sangat mirip. Rata-rata kandungan energi pada dataset TKPI tercatat sebesar 198,13 Kalori per 100 gram, sedangkan dataset Kaggle memiliki rata-rata sebesar 203,22 Kalori. Nilai median kedua dataset juga relatif serupa, yaitu 142 Kalori pada TKPI dan 146 Kalori pada Kaggle. Kesamaan pola ini menunjukkan bahwa kedua sumber data memiliki karakteristik nutrisi yang konsisten dan layak untuk diintegrasikan dalam satu basis data terpadu.

Pada komponen protein, rata-rata kandungan protein berada pada kisaran 9-10 gram per 100 gram bahan makanan dengan nilai maksimum mencapai lebih dari 70 gram. Nilai maksimum ini umumnya berasal dari produk pangan yang mengalami proses dehidrasi atau pengeringan sehingga konsentrasi proteinnya meningkat secara signifikan.

Komponen lemak menunjukkan pola yang menarik. Median kandungan lemak pada kedua dataset berada pada angka 2 gram, namun nilai maksimum mencapai 100 gram. Nilai tersebut secara ilmiah masih masuk akal karena berasal dari kelompok minyak atau lemak murni yang hampir seluruh komposisinya terdiri atas lemak.

Pada komponen karbohidrat, kedua dataset juga menunjukkan tingkat konsistensi yang tinggi dengan rata-rata sekitar 25 gram per 100 gram bahan pangan. Kesamaan distribusi ini memperkuat asumsi bahwa kedua dataset memiliki kualitas yang cukup baik untuk digabungkan.

Secara keseluruhan, hasil statistik deskriptif tidak menunjukkan adanya nilai negatif maupun anomali yang bertentangan dengan prinsip ilmu gizi sehingga dataset dinilai layak untuk diproses lebih lanjut.


e) Analisis Distribusi Kelompok Makanan

Selain mengevaluasi atribut numerik, audit kualitas data juga dilakukan terhadap atribut kategorikal untuk memahami representasi jenis makanan yang tersedia dalam dataset.

```
df_tkpi - Kelompok Makanan (value counts):
Kelompok Makanan
Sayur      227
Ikan dsb  179
Kacang     138
Serealia   135
Buah       129
Daging     122
Umbi       109
Bumbu      37
Telur      18
Lemak      18
Gula       18
Susu       17
Minuman    1

df_kaggle - Jumlah makanan unik : 1346
```

Hasil analisis menunjukkan bahwa dataset TKPI memiliki 13 kelompok makanan yang berbeda dengan distribusi yang relatif beragam.



Berdasarkan visualisasi distribusi kelompok makanan, kategori Sayur merupakan kelompok dengan jumlah item terbanyak, yaitu sebanyak 227 data. Posisi berikutnya ditempati oleh kelompok Ikan dan hasil laut sebanyak 179 data, diikuti kelompok Kacang-kacangan sebanyak 138 data, Serealialia sebanyak 135 data, Buah sebanyak 129 data, serta Daging sebanyak 122 data.

Distribusi ini menunjukkan bahwa dataset memiliki representasi yang baik terhadap berbagai sumber zat gizi utama, baik yang berasal dari komoditas nabati maupun hewani. Keberagaman kelompok makanan tersebut menjadi indikator penting bahwa dataset mampu menggambarkan pola konsumsi pangan masyarakat Indonesia secara lebih komprehensif. Dengan demikian, hasil analisis yang dihasilkan pada tahap berikutnya diharapkan memiliki tingkat representativitas yang lebih tinggi terhadap kondisi nyata di lapangan.

2.3 Data Cleaning

Data cleaning merupakan tahapan lanjutan setelah proses penilaian kualitas data (*data assessing*) yang bertujuan untuk memperbaiki, menyelaraskan, dan menyempurnakan kondisi dataset agar memenuhi standar kualitas yang diperlukan dalam proses analisis data dan pengembangan model kecerdasan buatan. Tahap ini berfokus pada penanganan berbagai permasalahan yang telah ditemukan sebelumnya, seperti inkonsistensi format data, nilai yang hilang (*missing values*), variasi penulisan teks, serta kebutuhan pembentukan atribut baru yang dapat meningkatkan kualitas analisis.

Meskipun sebagian koreksi tipe data telah dilakukan pada tahap assessing untuk memungkinkan analisis statistik deskriptif dilakukan secara valid, proses cleaning tetap diperlukan untuk menyempurnakan struktur dan isi data secara menyeluruh. Pada tahap ini dilakukan serangkaian proses pembersihan yang mencakup normalisasi teks, penanganan data hilang, dan ekstraksi fitur kategorikal baru yang akan digunakan pada analisis berikutnya.

Tujuan utama tahap data cleaning dalam proyek ini yaitu menyeragamkan format penulisan seluruh atribut teks, menghilangkan

inkonsistensi yang dapat mengganggu proses pencocokan data, menangani seluruh nilai yang hilang tanpa mengurangi jumlah data, dan menghasilkan dataset yang bersih, konsisten, dan siap digunakan pada tahap integrasi data serta eksplorasi lanjutan.

a) Normalisasi Teks Secara Sistematis

Setelah proses pemeriksaan kualitas data selesai dilakukan, ditemukan bahwa kedua dataset masih memiliki variasi format penulisan pada atribut teks. Variasi tersebut meliputi penggunaan huruf kapital dan huruf kecil yang tidak konsisten, keberadaan tanda baca yang tidak diperlukan, spasi ganda, serta spasi pada awal maupun akhir kalimat.

Permasalahan ini tampak sederhana, namun dapat menimbulkan dampak yang cukup besar pada tahap integrasi data. Sebagai contoh, dua makanan yang sebenarnya identik dapat dianggap berbeda oleh sistem hanya karena perbedaan penulisan huruf kapital atau keberadaan karakter tambahan tertentu. Kondisi ini dapat menyebabkan kegagalan proses pencocokan data (*matching*), memperbesar jumlah duplikasi semu, dan menurunkan kualitas hasil analisis.

Untuk mengatasi masalah tersebut, dibuat fungsi pembersihan teks yang diterapkan secara konsisten pada seluruh kolom teks utama pada kedua dataset. Fungsi ini melakukan beberapa tahapan secara berurutan, yaitu mengubah seluruh karakter menjadi huruf kecil (*lowercase*), menghapus karakter tanda baca yang tidak memiliki makna analitis, menghilangkan spasi berlebih, menghapus spasi di awal dan akhir kalimat, menstandarkan format penulisan agar seluruh data memiliki pola yang seragam. Proses normalisasi ini diterapkan pada kolom Nama Bahan Makanan, Kelompok Makanan, Mentah/Olahan pada dataset TKPI, serta kolom name pada dataset Kaggle yang merupakan atribut utama dalam proses pencocokan dan klasifikasi makanan.


```
Cleaning selesai.  
df_tkpi_clean   : (1148, 28)  
df_kaggle_clean : (1346, 7)
```

Gambar di atas menunjukkan hasil penerapan fungsi normalisasi teks pada kedua dataset. Seluruh nama makanan dan atribut kategorikal berhasil dikonversi ke dalam format yang seragam tanpa mengurangi jumlah data yang tersedia. Setelah proses normalisasi selesai dilakukan, seluruh atribut teks berhasil diseragamkan ke dalam format yang konsisten. Tidak ditemukan lagi variasi penulisan yang disebabkan oleh penggunaan huruf kapital, karakter tanda baca, maupun spasi yang tidak diperlukan. Dengan demikian, proses pencocokan nama makanan pada tahap integrasi dan deduplikasi dapat dilakukan dengan tingkat akurasi yang lebih tinggi.

Selain itu, proses normalisasi tidak mengubah jumlah observasi pada kedua dataset. Dataset TKPI tetap memiliki 1.148 baris data dengan 28 atribut, sedangkan dataset Kaggle tetap memiliki 1.346 baris data dengan 7 atribut. Hal ini menunjukkan bahwa normalisasi teks hanya memperbaiki format tanpa menghilangkan informasi yang terkandung dalam data.

b) Penanganan Missing Values

Berdasarkan hasil penilaian kualitas data pada subbab sebelumnya, ditemukan sejumlah nilai kosong (*missing values*) pada atribut nutrisi utama dataset TKPI, khususnya pada kolom Protein (g), Lemak (g), dan Karbohidrat (g). Apabila nilai kosong tersebut dibiarkan, maka proses perhitungan statistik, visualisasi data, maupun pengembangan model Machine Learning dapat menghasilkan hasil yang tidak optimal. Selain itu, banyak algoritma analitik yang tidak dapat memproses nilai kosong secara langsung sehingga dapat menyebabkan hilangnya sejumlah observasi ketika proses analisis dilakukan.

Terdapat beberapa strategi yang umum digunakan untuk menangani missing values, seperti penghapusan baris (*row deletion*), pengisian menggunakan nilai rata-rata (*mean imputation*), median, maupun metode

prediksi statistik lainnya. Namun, karakteristik data nutrisi pangan memiliki konteks yang berbeda dibandingkan data numerik umum. Berdasarkan penelusuran terhadap sumber data asli, nilai kosong yang ditemukan bukan disebabkan oleh kesalahan pencatatan atau kehilangan data, melainkan karena beberapa bahan pangan memang tidak memiliki kandungan zat gizi tertentu secara alami.

Untuk mengatasi permasalahan tersebut, proyek ini menggunakan pendekatan Zero Imputation, yaitu mengganti seluruh nilai kosong dengan angka 0. Pemilihan strategi ini tidak dilakukan secara sembarangan. Pada banyak kasus di dalam Tabel Komposisi Pangan Indonesia, nilai kosong muncul karena bahan pangan tertentu memang tidak mengandung zat gizi tertentu secara alami.

Nilai kosong lebih tepat diinterpretasikan sebagai nilai nol dibandingkan sebagai informasi yang tidak diketahui (*unknown value*). Dengan menggunakan Zero Imputation, seluruh informasi nutrisi tetap dapat dipertahankan tanpa perlu menghapus baris data yang sebenarnya masih memiliki nilai analitis yang tinggi.

```
Imputasi Selesai: Semua missing value makronutrisi telah diisi dengan nilai 0.0  
Jumlah Missing Value SETELAH Imputasi:  
Total missing di df_tkpi_clean : 0
```

Gambar di atas menunjukkan hasil pemeriksaan ulang jumlah missing values setelah proses imputasi dilakukan. Terlihat bahwa seluruh nilai kosong pada atribut nutrisi utama berhasil ditangani sehingga total missing values pada dataset TKPI menjadi nol. Dengan demikian, dataset telah terbebas dari permasalahan data hilang dan siap digunakan pada tahap analisis lanjutan. Keberhasilan proses ini juga memungkinkan seluruh observasi tetap dipertahankan sehingga ukuran dataset tidak berkurang dan variasi data nutrisi tetap terjaga secara maksimal.

c) Ekstraksi Fitur Kategorikal Jenis Makanan

Selain melakukan pembersihan data, tahap *cleaning* pada proyek ini juga mencakup proses pembentukan fitur baru (*feature extraction*). Langkah ini dilakukan untuk meningkatkan nilai analitis dataset dan mempermudah proses eksplorasi data pada tahap berikutnya. Berdasarkan tujuan bisnis proyek, diperlukan kemampuan untuk membedakan antara makanan yang berupa bahan tunggal dan makanan yang telah menjadi hidangan siap konsumsi. Oleh karena itu, dibentuk atribut baru bernama *jenis_makanan*. Kolom ini digunakan untuk mengelompokkan seluruh makanan ke dalam dua kategori utama yaitu *component* dan *dish*. *Component* merupakan bahan pangan tunggal atau bahan dasar yang belum mengalami proses pengolahan kompleks. Contohnya meliputi beras, ikan segar, telur, sayuran, buah-buahan, dan berbagai bahan baku pangan lainnya. Sedangkan *dish* merupakan makanan olahan yang telah siap dikonsumsi dan biasanya tersusun dari kombinasi beberapa bahan pangan. Contohnya meliputi nasi goreng, ayam goreng, mie ayam, sate, rendang, dan berbagai hidangan tradisional maupun modern lainnya. Proses klasifikasi dilakukan menggunakan pendekatan *keyword matching* berdasarkan nama makanan yang tersedia pada dataset.


```
Distribusi jenis_makanan – TKPI:  
jenis_makanan  
komponen      691  
dish          457  
Name: count, dtype: int64
```

Gambar di atas menunjukkan bahwa dari total 1.148 makanan pada dataset TKPI, sebanyak 691 item berhasil dikategorikan sebagai *component*, sedangkan 457 item lainnya dikategorikan sebagai *dish*. Dominasi kategori *component* merupakan hasil yang sangat logis mengingat TKPI pada dasarnya dirancang sebagai tabel komposisi pangan nasional yang berfokus pada pencatatan kandungan gizi bahan pangan dasar. Oleh karena itu, sebagian besar entri yang terdapat dalam dataset ini memang berupa bahan mentah atau bahan pangan tunggal. Di sisi lain, keberadaan 457 item

kategori dish menunjukkan bahwa dataset TKPI juga memiliki cakupan yang cukup baik terhadap berbagai makanan olahan tradisional Indonesia yang siap dikonsumsi.

```
Distribusi jenis_makanan – Kaggle:  
jenis_makanan  
komponen    940  
dish         406  
Name: count, dtype: int64
```

Pada dataset Kaggle, hasil klasifikasi menunjukkan bahwa sebanyak 940 item termasuk dalam kategori *component*, sedangkan 406 item termasuk dalam kategori *dish*. Dominasi kategori *component* menunjukkan bahwa dataset Kaggle juga memiliki koleksi bahan pangan dasar yang sangat kaya. Hal ini memberikan keuntungan besar ketika kedua dataset digabungkan karena variasi bahan pangan yang tersedia menjadi semakin luas. Sementara itu, keberadaan lebih dari 400 hidangan siap konsumsi memperkaya representasi makanan modern.



Gambar diatas memperlihatkan proporsi kategori dish dan component pada kedua dataset. Secara umum terlihat bahwa kategori component mendominasi baik pada dataset TKPI maupun Kaggle. Pada dataset TKPI, *component* memiliki proporsi sebesar 60.2%, dan *dish* sebesar 39.8% dari total 1.148 baris data. Sedangkan Pada dataset Kaggle, *component* memiliki proporsi sebesar 69.8%, dan dish sebesar 30.2% dari total 1.346 baris data.

Kesamaan pola distribusi ini menunjukkan bahwa kedua sumber data memiliki karakteristik yang relatif seimbang dan saling melengkapi. Kondisi tersebut menjadi keuntungan penting pada tahap integrasi data karena mengurangi risiko ketidakseimbangan distribusi kategori makanan setelah kedua dataset digabungkan menjadi satu basis data nutrisi terpadu.

2.4 Data Merging & Schema Standardization

Setelah seluruh proses pembersihan data selesai dilakukan, tahap berikutnya adalah penggabungan dataset (*data merging*) dan standarisasi skema (*schema standardization*). Tahap ini bertujuan untuk menyatukan dua sumber data yang memiliki struktur berbeda ke dalam satu format yang konsisten sehingga dapat dianalisis sebagai satu kesatuan pada tahap selanjutnya.

Meskipun dataset TKPI dan dataset Kaggle sama-sama berisi informasi kandungan nutrisi makanan, keduanya menggunakan struktur atribut, penamaan kolom, dan format penyimpanan yang berbeda. Perbedaan tersebut menyebabkan kedua dataset tidak dapat langsung digabungkan tanpa dilakukan penyelarasan terlebih dahulu. Oleh karena itu, diperlukan proses standarisasi skema untuk memastikan bahwa atribut yang merepresentasikan informasi yang sama memiliki nama dan format yang seragam.

Tujuan utama tahap ini adalah menyatukan dua sumber data nutrisi ke dalam satu dataset terpadu, menyamakan struktur atribut antar dataset agar dapat dibandingkan secara langsung, mempertahankan informasi asal data melalui atribut identitas sumber, membangun *single source of truth* yang akan digunakan pada seluruh tahapan analisis berikutnya, dan memperluas cakupan variasi makanan sehingga representasi data menjadi lebih komprehensif.

Tahap pertama yang dilakukan adalah menyelaraskan struktur kolom pada kedua dataset. Hasil pemeriksaan sebelumnya menunjukkan bahwa dataset TKPI dan Kaggle menggunakan penamaan atribut yang berbeda meskipun merepresentasikan informasi nutrisi yang sama. Sebagai contoh,

dataset TKPI menggunakan atribut Energi (Kal) untuk menunjukkan kandungan energi makanan, sedangkan dataset Kaggle menggunakan atribut calories. Perbedaan serupa juga ditemukan pada atribut protein, lemak, dan karbohidrat. Apabila perbedaan tersebut dibiarkan, proses penggabungan akan menghasilkan kolom yang terpisah dan menyebabkan inkonsistensi struktur data. Oleh karena itu, dilakukan proses column mapping atau pemetaan atribut untuk menyatukan seluruh informasi nutrisi ke dalam skema yang seragam.

Melalui proses ini, atribut nutrisi utama pada kedua dataset diselaraskan menjadi beberapa kolom standar, yaitu kalori, protein, lemak, karbohidrat, nama_makanan, dan jenis_makanan. Selain itu, ditambahkan kolom baru bernama source yang berfungsi sebagai penanda asal data. Kolom ini sangat penting untuk menjaga keterlacakan (data traceability) setelah proses penggabungan dilakukan. Setiap entri dari dataset TKPI diberi label "tkpi", sedangkan entri yang berasal dari Kaggle diberi label "kaggle".

Setelah seluruh atribut berhasil diseragamkan, kedua dataset digabungkan secara vertikal menggunakan fungsi `pd.concat()`. Metode ini dipilih karena kedua dataset memiliki struktur kolom yang telah identik setelah proses standardisasi dilakukan. Penggabungan secara vertikal berarti setiap baris data dari dataset TKPI dan Kaggle ditempatkan pada tabel yang sama dengan mempertahankan seluruh observasi yang tersedia. Dengan pendekatan ini, tidak ada data yang dihilangkan selama proses integrasi berlangsung. Hasil dari proses tersebut menghasilkan sebuah dataset baru bernama `df_merged`, yang berfungsi sebagai dataset induk (master dataset) untuk seluruh proses analisis lanjutan.


```
df_merged shape : (2494, 8)
Total rows      : 2494
```

	id	jenis_makanan	nama_makanan	kalori	protein	lemak	karbohidrat	source
0	1	komponen	blewah segar	34.0	0.8	0.2	8.2	tkpi
1	2	komponen	mentimun suri segar	16.0	1.3	0.0	2.1	tkpi
2	3	dish	nasi tim	120.0	2.4	0.4	26.0	tkpi
3	4	komponen	akar tonjong segar	45.0	1.1	0.4	10.8	tkpi
4	5	komponen	aletoge segar	37.0	4.4	0.5	3.8	tkpi
5	6	komponen	andaliman segar	99.0	4.6	1.0	18.0	tkpi
6	7	dish	ayam goreng pasundan dada	246.0	37.9	9.0	0.7	tkpi
7	8	dish	ayam goreng pasundan paha	245.0	33.1	11.4	0.3	tkpi
8	9	dish	ayam goreng pioneer dada	295.0	37.4	14.7	0.6	tkpi
9	10	dish	ayam goreng sukabumi dada	244.0	36.7	9.2	1.0	tkpi

Gambar di atas menunjukkan hasil proses penggabungan setelah kedua dataset berhasil disatukan ke dalam satu struktur tabel. Terlihat bahwa dataset akhir bernama `df_merged` berhasil terbentuk dengan total 2.494 baris data dan 8 kolom utama. Jumlah tersebut merupakan hasil penjumlahan langsung dari 1.148 data pada dataset TKPI dan 1.346 data pada dataset Kaggle.

Dataset `df_merged` yang terbentuk memiliki struktur yang jauh lebih sederhana dan terstandarisasi dibandingkan struktur awal kedua dataset. Seluruh informasi nutrisi kini tersimpan dalam delapan atribut utama, yaitu `id`, `nama_makanan`, `jenis_makanan`, `kalori`, `protein`, `lemak`, `karbohidrat`, dan `source`. Struktur yang seragam ini memberikan beberapa keuntungan penting. Pertama, proses analisis menjadi lebih sederhana karena seluruh makanan kini berada dalam satu tabel yang konsisten. Kedua, seluruh atribut nutrisi menggunakan format yang sama sehingga perbandingan antar makanan dapat dilakukan secara langsung tanpa memerlukan transformasi tambahan. Ketiga, keberadaan atribut `source` memungkinkan proses pelacakan asal data tetap terjaga meskipun kedua dataset telah digabungkan.

Untuk memahami komposisi dataset hasil penggabungan, dilakukan analisis terhadap jumlah kontribusi data dari masing-masing sumber.



Berdasarkan grafik distribusi sumber data, terlihat bahwa dataset Kaggle memberikan kontribusi terbesar terhadap dataset gabungan dengan total 1.346 entri makanan atau sekitar 54% dari keseluruhan data. Jumlah ini menunjukkan bahwa dataset komunitas memiliki cakupan variasi makanan yang sangat luas, khususnya pada kategori makanan modern dan produk komersial yang banyak dikonsumsi masyarakat saat ini.

Sementara itu, dataset TKPI menyumbangkan sebanyak 1.148 entri atau sekitar 46% dari total data. Meskipun jumlahnya sedikit lebih kecil dibandingkan Kaggle, kontribusi dataset TKPI memiliki nilai yang sangat penting karena menyediakan referensi nutrisi yang berasal dari sumber resmi pemerintah dan telah digunakan sebagai standar nasional dalam bidang gizi.

BAB III

DEDUPLIKASI PARSIAL & FEATURE ENGINEERING

3.1 Pembersihan Redundansi Berlapis (*Fuzzy String Matching*)

Setelah proses penggabungan dataset selesai dilakukan pada Bab II, diperoleh dataset (`df_merged`) yang berisi 2.494 entri makanan dari dua sumber berbeda, yaitu TKPI dan Kaggle. Meskipun kedua dataset telah berhasil disatukan ke dalam satu skema yang seragam, masih terdapat potensi redundansi data akibat keberadaan nama makanan yang sama atau sangat mirip namun berasal dari sumber yang berbeda.

Keberadaan data redundan dapat menimbulkan berbagai masalah dalam proses analisis. Suatu makanan yang tercatat lebih dari satu kali akan memiliki bobot yang lebih besar dibandingkan makanan lainnya, sehingga dapat memengaruhi distribusi statistik, hasil visualisasi, maupun interpretasi bisnis yang dihasilkan. Oleh karena itu, sebelum memasuki tahap *Exploratory Data Analysis* (EDA), diperlukan proses deduplikasi untuk memastikan bahwa setiap makanan hanya direpresentasikan satu kali pada dataset akhir.

Pada penelitian ini, proses deduplikasi dilakukan secara berlapis (multi-stage deduplication) menggunakan dua pendekatan utama, yaitu *Exact Matching* dan *Fuzzy String Matching*. *Exact Matching* untuk mendeteksi nama makanan yang identik secara sempurna, sedangkan *Fuzzy String Matching*, untuk mendeteksi variasi penulisan, singkatan, kesalahan ketik (*typo*), maupun perbedaan ejaan lokal yang merujuk pada makanan yang sama.

Sebelum proses deduplikasi dilakukan, dibuat sebuah dataframe baru bernama `df_food` sebagai salinan penuh (*copy*) dari dataset hasil integrasi (`df_merged`). Pendekatan ini dipilih untuk menjaga keamanan data asli sehingga seluruh proses deduplikasi dapat dilakukan tanpa mengubah dataset induk. Pada tahap awal ini, `df_food` masih memiliki dimensi yang sama dengan `df_merged`, yaitu sebanyak 2.494 baris dan 8 kolom utama. Struktur data pada dataset ini juga telah berada dalam kondisi yang konsisten. Seluruh atribut nutrisi utama seperti kalori, protein, lemak, dan karbohidrat telah

menggunakan tipe data numerik (float64), sedangkan atribut identitas dan kategorikal seperti nama makanan, jenis makanan, dan sumber data tetap menggunakan tipe data teks (object).

Tahap pertama dalam proses deduplikasi adalah mendeteksi nama makanan yang memiliki kesamaan teks secara sempurna. Metode *exact matching* bekerja dengan membandingkan setiap nilai pada kolom nama_makanan. Apabila ditemukan dua atau lebih entri dengan nama yang sama persis, maka sistem akan mempertahankan satu entri dan menghapus sisanya. Pendekatan ini efektif untuk menghilangkan redundansi yang muncul akibat penggabungan dua dataset berbeda yang sama-sama mencatat makanan yang identik.

Meskipun metode *exact matching* mampu menghilangkan duplikasi sempurna, pendekatan tersebut tidak dapat mendeteksi makanan yang sebenarnya sama tetapi ditulis dengan variasi ejaan yang berbeda. Permasalahan ini cukup umum ditemukan pada dataset pangan Indonesia karena adanya perbedaan dialek daerah, variasi penulisan lokal, penggunaan singkatan, maupun kesalahan pengetikan (*typing errors*). Untuk mengatasi masalah tersebut, digunakan pendekatan *Fuzzy String Matching* berbasis *SequenceMatcher Similarity Ratio*. Metode ini bekerja dengan menghitung tingkat kemiripan antar dua teks dalam rentang nilai 0 hingga 1. Semakin tinggi nilai yang dihasilkan, semakin besar kemungkinan kedua nama tersebut merujuk pada objek makanan yang sama. Selain mempertimbangkan kemiripan teks, proses validasi juga memperhatikan kesamaan profil nutrisi sehingga makanan yang kebetulan memiliki nama mirip tetapi berbeda kandungan gizi tidak akan terhapus secara keliru.

```

Duplikat nama_makanan (exact Match) sebelum deduplikasi: 840
Mendeteksi kemiripan: 'daun talas rebus' dengan 'daun tales rebus' (Nutrisi sama). Menyimpan 'daun talas rebus'
Mendeteksi kemiripan: 'taoge seduh' dengan 'toge seduh' (Nutrisi sama). Menyimpan 'taoge seduh'
Mendeteksi kemiripan: 'kacang tolo tunggak rebus' dengan 'kacang tunggak rebus' (Nutrisi sama). Menyimpan 'kacang tolo tunggak rebus'
Mendeteksi kemiripan: 'asam kandis kering' dengan 'asan kandis kering' (Nutrisi sama). Menyimpan 'asam kandis kering'
Mendeteksi kemiripan: 'ayam goreng church texas sayap' dengan 'ayam goreng church texa sayap' (Nutrisi sama). Menyimpan 'ayam goreng church texas sayap'
Mendeteksi kemiripan: 'ikan mujahir goreng' dengan 'ikan mujair goreng' (Nutrisi sama). Menyimpan 'ikan mujahir goreng'
Mendeteksi kemiripan: 'ikan mujahir pepes' dengan 'ikan mujair pepes' (Nutrisi sama). Menyimpan 'ikan mujahir pepes'
Mendeteksi kemiripan: 'ikan mujahir dendeng mentah' dengan 'ikan mujair dendeng mentah' (Nutrisi sama). Menyimpan 'ikan mujahir dendeng mentah'
Mendeteksi kemiripan: 'ikan mujahir segar' dengan 'ikan mujair segar' (Nutrisi sama). Menyimpan 'ikan mujahir segar'
Mendeteksi kemiripan: 'jagung gerontol' dengan 'jagung grontol' (Nutrisi sama). Menyimpan 'jagung gerontol'
Mendeteksi kemiripan: 'pepes oncom ampas tahu' dengan 'pepea oncom ampas tahu' (Nutrisi sama). Menyimpan 'pepes oncom ampas tahu'
Mendeteksi kemiripan: 'kacang merahbada kering' dengan 'kacang merah banda kering' (Nutrisi sama). Menyimpan 'kacang merahbada kering'
Mendeteksi kemiripan: 'lemarebung asam' dengan 'lema rebung asam' (Nutrisi sama). Menyimpan 'lemarebung asam'
Mendeteksi kemiripan: 'pelolah manuk masakan' dengan 'pelepah manuk masakan' (Nutrisi sama). Menyimpan 'pelolah manuk masakan'
Mendeteksi kemiripan: 'tinoransa masakan' dengan 'tinoransak masakan' (Nutrisi sama). Menyimpan 'tinoransa masakan'
Mendeteksi kemiripan: 'anak sapi daging kurus segar' dengan 'sapi daging kurus segar' (Nutrisi sama). Menyimpan 'anak sapi daging kurus segar'
Mendeteksi kemiripan: 'babi daging gemuksegar' dengan 'babi daging gemuk segar' (Nutrisi sama). Menyimpan 'babi daging gemuksegar'
Mendeteksi kemiripan: 'kacang tanah rebus dg kulit' dengan 'kacang tanah rebus berkulit' (Nutrisi sama). Menyimpan 'kacang tanah rebus dg kulit'
Mendeteksi kemiripan: 'kelapa setengah tua daging segar' dengan 'kelapa setengah tua daging' (Nutrisi sama). Menyimpan 'kelapa setengah tua daging segar'
Mendeteksi kemiripan: 'telur bebek bagian putih segar' dengan 'telur bebek bagian putih' (Nutrisi sama). Menyimpan 'telur bebek bagian putih segar'

Jumlah baris dihapus melalui Fuzzy Matching: 20
df_food setelah deduplikasi final: (1634, 8)

```

Gambar di atas menunjukkan hasil akhir proses deduplikasi berlapis yang diterapkan pada dataset gabungan. Terlihat bahwa jumlah data berhasil berkurang dari 2.494 menjadi 1.634 entri unik tanpa kehilangan variasi makanan yang benar-benar berbeda. Secara keseluruhan, proses deduplikasi berhasil menghapus 840 duplikat mutlak (*exact duplicates*) dan 20 duplikasi berbasis kemiripan teks (*fuzzy duplicates*). Dengan demikian, total sebanyak 860 entri redundan berhasil dieliminasi dari dataset. Pengurangan ini menunjukkan bahwa sebagian besar redundansi pada dataset berasal dari pencatatan makanan yang sama pada sumber data yang berbeda atau variasi penulisan nama makanan yang tidak konsisten. Proses ini sangat penting karena memastikan bahwa setiap makanan hanya direpresentasikan satu kali sehingga hasil analisis yang dihasilkan pada tahap berikutnya menjadi lebih objektif dan bebas dari bias frekuensi.

3.2 Advanced Feature Engineering

Setelah dataset berhasil dibersihkan dari berbagai bentuk redundansi, langkah berikutnya adalah melakukan feature engineering. Feature engineering merupakan proses membangun atribut baru dari kombinasi atribut yang telah ada untuk menghasilkan informasi yang lebih bermakna dan mudah diinterpretasikan. Dalam analisis nutrisi, kandungan protein, lemak, karbohidrat, dan kalori saja sering kali belum cukup untuk menjelaskan kualitas gizi suatu makanan secara komprehensif. Oleh karena itu, dilakukan pembentukan sejumlah metrik turunan yang dapat menggambarkan efisiensi nutrisi, keseimbangan makronutrien, serta

karakteristik gizi makanan secara lebih mendalam. Sebanyak lima fitur baru berhasil dibentuk pada dataset `df_food`, yaitu:

a. *Protein Per Calorie*

Fitur ini dihitung dengan membandingkan jumlah protein terhadap total kalori yang dimiliki suatu makanan. Metrik ini digunakan untuk mengukur efisiensi protein atau seberapa besar kandungan protein yang diperoleh dari setiap satuan energi yang dikonsumsi. Semakin tinggi nilainya, semakin baik makanan tersebut sebagai sumber protein rendah kalori.

b. *Fat Per Calorie*

Fitur ini mengukur proporsi kandungan lemak terhadap total energi. Metrik ini digunakan untuk mengidentifikasi makanan dengan densitas lemak tinggi maupun rendah.

c. *Carb Per Calorie*

Fitur ini menunjukkan tingkat kepadatan karbohidrat terhadap total energi. Metrik ini sangat berguna untuk mengidentifikasi makanan sumber energi utama seperti sereal, umbi-umbian, dan produk berbasis tepung. Nilai tersebut mencerminkan karakteristik pola pangan Indonesia yang masih didominasi oleh sumber karbohidrat.

d. *Protein Fat Ratio*

Fitur ini menghitung perbandingan langsung antara kandungan protein dan lemak. Makanan dengan nilai rasio tinggi menunjukkan karakteristik tinggi protein dan rendah lemak sehingga sering dianggap lebih ideal untuk kebutuhan diet tertentu.

e. *Macro Balance Score*

Fitur ini dikembangkan untuk mengukur tingkat keseimbangan distribusi energi yang berasal dari protein, lemak, dan karbohidrat. Skor berada pada rentang 0 hingga 1. Semakin mendekati angka 1, semakin seimbang komposisi makronutrien makanan tersebut.


```
Fitur baru yang dibuat:
protein_per_calorie      mean=0.0598
fat_per_calorie          mean=122.4275
carb_per_calorie         mean=0.1433
protein_fat_ratio        mean=36297.1497
macro_balance_score      mean=0.6990
```

Nilai rata-rata *protein_per_calorie* sebesar 0,0598 menunjukkan bahwa secara umum setiap satu kalori makanan dalam dataset menyumbang sekitar 0,06 gram protein. Sementara itu, nilai *carb_per_calorie* yang lebih tinggi menunjukkan bahwa sebagian besar makanan dalam dataset masih didominasi oleh sumber energi berbasis karbohidrat. Nilai rata-rata *macro_balance_score* sebesar 0,699 mengindikasikan bahwa mayoritas makanan dalam dataset memiliki distribusi zat gizi makro yang cukup berimbang dan tidak didominasi secara ekstrem oleh satu jenis nutrisi saja. Dengan adanya fitur-fitur baru ini, kemampuan analisis dataset menjadi jauh lebih kaya dibandingkan hanya menggunakan atribut gizi standar.

3.3 Analisis Distribusi Fitur Baru

Setelah proses deduplikasi selesai dilakukan, tahap berikutnya adalah menganalisis karakteristik distribusi dari fitur-fitur baru hasil feature engineering. Analisis ini bertujuan untuk memahami pola persebaran data, mengidentifikasi dominasi nilai tertentu, serta mengevaluasi apakah fitur yang dibentuk mampu merepresentasikan karakteristik nutrisi makanan secara lebih baik dibandingkan atribut gizi dasar.

Sebelum visualisasi dilakukan, seluruh fitur rasio terlebih dahulu melewati proses penanganan pencilan (*outlier handling*) menggunakan metode *percentile clipping* pada persentil ke-99. Pendekatan ini diterapkan karena beberapa jenis makanan memiliki nilai nutrisi yang sangat ekstrem. Nilai-nilai ekstrem tersebut berpotensi mendistorsi bentuk distribusi dan menyebabkan mayoritas data sulit diamati secara visual. Dengan membatasi nilai maksimum pada persentil ke-99, pola distribusi utama dapat ditampilkan dengan lebih jelas tanpa menghilangkan karakteristik umum dataset.



Gambar di atas menampilkan distribusi kelima fitur turunan yang telah dibentuk dari kombinasi nilai kalori, protein, lemak, dan karbohidrat. Visualisasi ini memberikan gambaran mengenai pola persebaran karakteristik nutrisi makanan yang tidak dapat diamati hanya dari data mentah. Melalui histogram tersebut dapat diketahui kecenderungan dominasi makronutrien, tingkat efisiensi protein terhadap energi, serta keseimbangan komposisi nutrisi pada setiap makanan.

Berdasarkan histogram *protein_per_calorie*, terlihat bahwa distribusi data cenderung membentuk pola *right-skewed* atau menceng ke kanan. Sebagian besar makanan terkonsentrasi pada rentang nilai yang relatif rendah hingga sedang, sedangkan sejumlah kecil makanan dengan kandungan protein yang sangat tinggi membentuk ekor distribusi pada sisi kanan grafik. Nilai rata-rata sebesar 0,0598 menunjukkan bahwa secara umum setiap satu kalori yang dikonsumsi dari makanan dalam dataset menyumbang sekitar 0,06 gram protein. Pola ini mengindikasikan bahwa hanya sebagian kecil makanan yang memiliki efisiensi protein sangat tinggi, sementara mayoritas makanan memiliki kandungan protein yang lebih moderat.

Pada fitur *carb_per_calorie*, distribusi terlihat lebih menyebar dibandingkan fitur protein. Sebaran ini menunjukkan keberagaman sumber karbohidrat yang terdapat dalam dataset, mulai dari sayuran dengan kandungan karbohidrat rendah hingga makanan pokok dan produk olahan

yang memiliki kepadatan karbohidrat tinggi. Nilai rata-rata sebesar 0,1433 mengonfirmasi bahwa karbohidrat masih menjadi komponen dominan dalam banyak makanan yang tercatat pada dataset, sejalan dengan pola konsumsi pangan masyarakat Indonesia yang banyak bergantung pada sumber energi berbasis sereal dan umbi-umbian.

Histogram *fat_per_calorie* memperlihatkan pola distribusi yang berbeda. Sebagian besar data terkonsentrasi pada rentang nilai tertentu dengan adanya penumpukan frekuensi yang cukup tinggi di area atas distribusi. Hal ini dipengaruhi oleh keberadaan komoditas minyak, margarin, santan, dan produk lemak murni lainnya yang memiliki kandungan lemak sangat dominan. Nilai rata-rata sebesar 122,4275 menunjukkan bahwa distribusi fitur ini masih dipengaruhi oleh kelompok makanan berlemak tinggi meskipun pencilan ekstrem telah dibatasi melalui proses clipping.

Sementara itu, distribusi *protein_fat_ratio* menunjukkan tingkat ketidaksimetrian yang paling tinggi dibandingkan fitur lainnya. Sebagian besar makanan berada pada nilai rasio rendah hingga menengah, namun terdapat sejumlah kecil makanan dengan rasio yang sangat besar sehingga membentuk ekor distribusi yang panjang. Kondisi ini terjadi karena beberapa bahan pangan memiliki kandungan protein yang cukup tinggi tetapi kadar lemaknya sangat rendah atau bahkan mendekati nol. Secara matematis, kondisi tersebut menghasilkan nilai rasio yang sangat besar. Meskipun rata-rata fitur ini mencapai 36.297,1497, sebagian besar observasi sebenarnya terkonsentrasi pada nilai yang jauh lebih rendah.

Berbeda dengan empat fitur sebelumnya, distribusi *macro_balance_score* menunjukkan pola yang relatif stabil dan lebih mendekati distribusi normal. Sebagian besar makanan berada pada rentang skor menengah hingga tinggi, yaitu antara sekitar 0,52 hingga 0,95, dengan nilai rata-rata sebesar 0,6990. Sebaran ini menunjukkan bahwa mayoritas makanan dalam dataset memiliki kombinasi makronutrien yang cukup beragam dan tidak hanya didominasi oleh satu zat gizi tertentu. Dengan kata lain, sebagian besar makanan memiliki tingkat keseimbangan nutrisi yang

relatif baik jika ditinjau dari proporsi protein, lemak, dan karbohidrat yang dikandungnya.

Secara keseluruhan, hasil visualisasi distribusi fitur menunjukkan bahwa proses *feature engineering* berhasil menghasilkan indikator baru yang mampu menggambarkan karakteristik nutrisi makanan secara lebih mendalam dibandingkan atribut gizi dasar. Informasi mengenai densitas protein, kepadatan karbohidrat, dominasi lemak, serta tingkat keseimbangan makronutrien yang diperoleh dari fitur-fitur ini akan menjadi landasan penting dalam menjawab pertanyaan bisnis pada tahap *Exploratory Data Analysis* (EDA) pada bab berikutnya.

BAB IV

EXPLORATORY DATA ANALYSIS (EDA) & VISUALISASI DATA


Exploratory Data Analysis (EDA) merupakan proses eksplorasi dan investigasi data yang dilakukan sebelum pembangunan model maupun penarikan kesimpulan bisnis. Tahap EDA pada penelitian ini dilakukan untuk menjawab lima pertanyaan bisnis utama yang telah dirumuskan pada Bab I. Tujuan utama EDA adalah memahami karakteristik dataset, menemukan pola tersembunyi, dan mengidentifikasi hubungan antarvariabel. Dalam penelitian ini, EDA dilakukan terhadap dataset final `df_food` yang telah melalui proses pembersihan, deduplikasi, dan rekayasa fitur pada bab sebelumnya. Analisis dilakukan menggunakan pendekatan statistik deskriptif dan visualisasi data sehingga informasi yang terkandung dalam dataset dapat dipahami secara lebih komprehensif.

Visualisasi data merupakan proses penyajian informasi dalam bentuk grafik sehingga pola dan hubungan antarvariabel dapat diamati dengan lebih mudah dibandingkan melalui tabel numerik. Pada proses ini digunakan beberapa jenis visualisasi, yaitu Horizontal Bar Chart, Heatmap Correlation Matrix, Comparative Bar Chart, dan Histogram Distribution. Kombinasi EDA dan visualisasi data digunakan untuk menjawab seluruh pertanyaan bisnis (*Business Questions*) yang telah dirumuskan pada tahap perencanaan proyek.

4.1 BQ1: Makanan dengan Kandungan Protein Tertinggi

Analisis ini dilakukan untuk menjawab pertanyaan bisnis pertama yaitu "Makanan apa yang memiliki kandungan protein tertinggi dalam dataset?". Untuk menjawab pertanyaan tersebut, seluruh makanan pada dataset diurutkan berdasarkan kandungan protein per 100 gram dan dipilih sepuluh makanan dengan nilai tertinggi.

BQ1 – Top 10 Makanan dengan Protein Tertinggi (per 100g):				
nama_makanan	jenis_makanan	protein	kalori	
kerupuk kulit kerbau	komponen	83.0	422.0	
dendeng mujahir goreng	dish	74.3	598.0	
ikan mujair dendeng goreng	dish	74.3	598.0	
ikan kayu kering	dish	70.7	302.0	
ikan teri kering tawar mentah	komponen	68.7	331.0	
ikan teri kering tawar	komponen	68.7	331.0	
ikan mujahir dendeng mentah	komponen	68.3	582.0	
udang kering mentah	komponen	62.6	278.0	
udang kering	komponen	62.4	295.0	
ikan sale lais mentah	dish	61.3	415.0	



Berdasarkan gambar di atas, diketahui bahwa Kerupuk Kulit Kerbau menempati posisi pertama sebagai makanan dengan kandungan protein tertinggi dalam dataset, yaitu sebesar 83 gram protein per 100 gram bahan. Posisi berikutnya ditempati oleh berbagai produk olahan ikan dan hasil laut yang telah mengalami proses pengeringan, seperti Dendeng Mujair Goreng, Ikan Kayu Kering, Ikan Teri Kering Tawar, dan Udang Kering.

Temuan ini menunjukkan bahwa mayoritas makanan dengan kandungan protein tertinggi berasal dari kelompok pangan hewani yang mengalami proses dehidrasi. Pengurangan kadar air selama proses pengeringan menyebabkan kandungan zat gizi menjadi lebih terkonsentrasi sehingga nilai protein per satuan berat meningkat secara signifikan.

Selain itu, terlihat bahwa kategori makanan dengan protein tinggi tidak hanya berasal dari kelompok komponen (bahan pangan mentah), tetapi juga dari kategori dish atau makanan olahan. Namun, makanan olahan yang muncul dalam daftar ini sebagian besar tetap berbasis bahan tunggal tanpa penambahan

komponen karbohidrat dalam jumlah besar sehingga kepadatan proteinnya tetap terjaga.

Jika ditinjau dari sisi kalori, terdapat perbedaan yang cukup besar antar makanan. Beberapa produk seperti dendeng memiliki kandungan protein tinggi namun juga disertai kalori yang tinggi akibat proses penggorengan dan peningkatan kandungan lemak. Sebaliknya, produk seperti ikan kayu kering dan udang kering menunjukkan efisiensi yang lebih baik karena mampu menyediakan protein tinggi dengan beban kalori yang relatif lebih rendah.


Berdasarkan hasil analisis, makanan dengan kandungan protein tertinggi dalam dataset adalah Kerupuk Kulit Kerbau (83 g/100 g), diikuti oleh kelompok olahan ikan kering seperti Dendeng Mujair Goreng (74,3 g) dan Ikan Kayu Kering (70,7 g). Secara umum, makanan dengan kandungan protein tertinggi didominasi oleh produk hewani yang telah mengalami proses pengeringan sehingga menghasilkan konsentrasi protein yang sangat tinggi.

4. 2 BQ2: Rasio Protein terhadap Kalori Tertinggi (*Protein Efficiency*)

Analisis ini bertujuan menjawab pertanyaan bisnis kedua yaitu "Makanan (dish) apa yang memiliki rasio protein terhadap kalori paling tinggi sebagai indikator efisiensi sumber protein?". Berbeda dengan BQ1 yang hanya melihat jumlah protein mutlak, analisis ini mempertimbangkan efisiensi protein terhadap energi yang masuk ke tubuh.

BQ2 – Top 10 Rasio Protein per Kalori (Dish Only):

nama_makanan	protein	kalori	protein_per_calorie
jukku pallu kaloa masakan	15.2	15.0	1.013333
ikan kayu kering	70.7	302.0	0.234106
olaholah	2.1	9.0	0.233333
ikan teri nasi kering	32.5	144.0	0.225694
ikan gabus kering	58.0	268.0	0.216418
pindang ikan layang	30.0	153.0	0.196078
ikan katombo asin	31.7	162.0	0.195679
ikan selar kuning cue mentah	27.0	138.0	0.195652
pindang ikan selar kecil	27.0	142.0	0.190141
pindang ikan benggol	31.0	170.0	0.182353




Hasil analisis menunjukkan bahwa Jukku Pallu Kaloa Masakan memiliki nilai rasio protein terhadap kalori tertinggi dengan skor sebesar 1,013. Nilai tersebut menunjukkan bahwa setiap satu kalori yang dikonsumsi dari makanan tersebut disertai hampir satu gram protein. Dominasi ini berasal dari berbagai olahan ikan tradisional Indonesia seperti ikan kayu kering, ikan teri nasi kering, ikan gabus kering, dan berbagai jenis pindang. Pola ini menunjukkan bahwa teknik pengolahan tradisional seperti pengeringan, perebusan, dan pengasapan mampu mempertahankan kandungan protein tinggi tanpa meningkatkan kalori secara signifikan. Temuan ini memperlihatkan bahwa makanan berbasis ikan laut merupakan sumber protein paling efisien dalam dataset. Kelompok makanan ini sangat potensial direkomendasikan untuk program diet tinggi protein dan rendah kalori.

4. 3 BQ3: Makanan dengan Kepadatan Energi Tertinggi

Analisis ini bertujuan menjawab pertanyaan bisnis ketiga yaitu "Makanan apa yang memiliki kepadatan energi tertinggi berdasarkan jumlah kalori per gram makanan?"

BQ3 – Top 10 Kepadatan Energi Tertinggi:

nama_makanan	jenis_makanan	kalori
opak singkong	komponen	940.0
lemak babi lard	komponen	902.0
minyak hiu hati	komponen	902.0
minyak ikan	komponen	902.0
minyak kacang tanah	komponen	902.0
lemak babi	komponen	902.0
minyak hati hiu eulamia	komponen	902.0
minyak kelapa sawit	komponen	884.0
minyak zaitun	komponen	884.0
minyak kedelai	komponen	883.0




Berdasarkan hasil pengurutan nilai kalori, Opak Singkong menempati posisi pertama dengan kandungan energi sebesar 940 Kalori per 100 gram. Posisi berikutnya didominasi oleh berbagai produk minyak dan lemak murni seperti minyak ikan, minyak kacang tanah, minyak zaitun, dan lemak babi. Hal ini sangat sesuai dengan prinsip ilmu gizi karena lemak memiliki densitas energi tertinggi dibandingkan makronutrien lainnya. Setiap satu gram lemak menghasilkan sekitar sembilan kalori, sedangkan protein dan karbohidrat hanya menghasilkan empat kalori per gram. Menariknya, Opak Singkong mampu melampaui berbagai minyak murni karena kombinasi kandungan pati kering dan penyerapan minyak yang tinggi selama proses pengolahan.

4. 4 BQ4: Korelasi Antar Makronutrien

Analisis ini bertujuan menjawab pertanyaan bisnis keempat yaitu "Zat gizi makro (protein, lemak, atau karbohidrat) mana yang memiliki koefisien korelasi terkuat dalam mempengaruhi total kalori makanan pada dataset?".

BQ4 — Korelasi Antar Makronutrien:

	kalori	protein	lemak	karbohidrat
kalori	1.000	0.367	0.754	0.453
protein	0.367	1.000	0.227	-0.117
lemak	0.754	0.227	1.000	0.001
karbohidrat	0.453	-0.117	0.001	1.000



Hasil matriks korelasi menunjukkan bahwa variabel lemak memiliki hubungan paling kuat terhadap kalori dengan koefisien korelasi sebesar 0,754. Nilai tersebut jauh lebih tinggi dibandingkan korelasi karbohidrat terhadap kalori (0,453) maupun protein terhadap kalori (0,367). Temuan ini mengonfirmasi teori gizi bahwa lemak merupakan kontributor energi terbesar pada makanan.


Selain itu, hubungan antar makronutrien menunjukkan korelasi yang sangat rendah. Karbohidrat dan lemak hampir tidak memiliki hubungan sama sekali (0,001), sedangkan protein dan karbohidrat menunjukkan korelasi negatif yang sangat lemah (-0,117). Kondisi ini menunjukkan bahwa masing-masing makronutrien dapat diperlakukan sebagai variabel independen tanpa adanya masalah multikolinearitas yang berarti.

Lemak merupakan faktor yang paling menentukan peningkatan total kalori makanan. Oleh karena itu, dalam sistem rekomendasi makanan maupun estimasi nutrisi otomatis, prediksi kandungan lemak menjadi komponen yang paling krusial untuk memperoleh estimasi kalori yang akurat.

4.5 BQ5: Perbandingan Profil Nutrisi Dish dan Komponen

Analisis ini bertujuan menjawab pertanyaan bisnis kelima yaitu "Apakah terdapat perbedaan profil nutrisi yang signifikan antara kategori makanan dish dan component?".

BQ5 – Profil Nutrisi Rata-rata per Jenis Makanan:				
	kalori	protein	lemak	karbohidrat
jenis_makanan				
dish	235.55	9.74	9.14	28.17
komponen	174.80	9.52	6.39	22.23



Hasil perhitungan rata-rata menunjukkan bahwa kategori dish memiliki kandungan kalori rata-rata sebesar 235,55 Kal, sedangkan kategori komponen hanya sebesar 174,80 Kal. Perbedaan ini menunjukkan bahwa proses pengolahan makanan berkontribusi terhadap peningkatan densitas energi. Pada aspek lemak, kategori *dish* memiliki rata-rata 9,14 gram, sedangkan kategori komponen hanya 6,39 gram. Kenaikan ini kemungkinan besar disebabkan oleh penggunaan minyak, santan, atau teknik pengolahan seperti menggoreng dan menumis. Karbohidrat juga mengalami peningkatan dari 22,23 gram menjadi

28,17 gram pada kategori dish. Sebaliknya, kandungan protein relatif stabil pada kedua kelompok, yaitu sekitar 9,5–9,7 gram.

Makanan olahan (dish) memiliki karakteristik yang lebih tinggi kalori, lebih tinggi lemak, dan lebih tinggi karbohidrat dibandingkan bahan pangan mentah (komponen). Namun demikian, kandungan protein relatif tetap stabil pada kedua kategori. Temuan ini menunjukkan bahwa proses pengolahan makanan di Indonesia cenderung meningkatkan kepadatan energi tanpa memberikan peningkatan protein yang signifikan.

BAB V

EKSPERIMEN STATISTIK (A/B TESTING)

A/B Testing (pengujian hipotesis statistik dua sampel) merupakan sebuah metodologi ilmiah yang digunakan untuk membandingkan dua kelompok variabel guna menentukan apakah terdapat perbedaan performa atau karakteristik yang signifikan di antara keduanya. Pendekatan ini memisahkan subjek ke dalam dua varian, yaitu Kelompok Kontrol (Grup A) yang merepresentasikan kondisi dasar atau standar, dan Kelompok Varian (Grup B) yang merepresentasikan elemen baru atau pembanding yang ingin diuji kualitasnya.

Pada proyek pengembangan sistem cerdas GiSee, implementasi A/B Testing diadopsi bukan untuk menguji antarmuka pengguna, melainkan sebagai instrumen validasi ilmiah terhadap hasil rekayasa fitur (*feature engineering*) yang telah dieksekusi pada data tabular pangan. Tujuan utama dari eksperimen statistik ini meliputi dua urgensi strategis, yaitu:

1. Membuktikan secara objektif menggunakan kaidah matematika apakah intervensi teknik kuliner (proses memasak dan peracikan hidangan) memberikan dampak perubahan yang nyata terhadap keseimbangan nilai gizi makro (*Macro Balance Score*) suatu makanan jika dibandingkan dengan kondisi murninya saat masih berupa bahan baku tunggal mentah.
2. Memastikan bahwa pemisahan kategori jenis_makanan (*Dish & Component*) memiliki landasan varians data yang kokoh dan bukan sekadar klasifikasi acak yang bersifat gangguan (*noise*). Meskipun basis data nutrisi ini tidak digunakan sebagai data latih (*training data*) dalam model inti, pembuktian signifikansi data ini sangat vital untuk memperkaya fungsionalitas sistem rekomendasi menu pasca-deteksi visual.

Pengujian statistik dijalankan menggunakan metode Welch's t-test (Independent Two-Sample T-Test dengan asumsi varians tidak homogen). Pilihan ini diambil karena kedua kelompok data memiliki ukuran sampel (N) yang tidak berimbang serta sebaran varians yang berbeda secara natural. Eksperimen statistik ini dikondisikan melalui parameter pengujian sebagai berikut.

1. Grup A (Dish): Kelompok hidangan jadi atau makanan olahan siap konsumsi yang merepresentasikan hasil intervensi kuliner lokal.
2. Grup B (Komponen): Kelompok bahan baku makanan tunggal, murni, atau mentah yang merepresentasikan kondisi gizi dasar tanpa intervensi eksternal.
3. Variabel yang Diuji: *macro_balance_score* (Skor kalkulasi kedekatan proporsi distribusi tiga zat gizi makro pada skala 0 hingga 1).
4. Tingkat Signifikansi $\alpha = 0.05$ (Tingkat Kepercayaan 95%).

Formulasi hipotesis yang diajukan dalam A/B Testing ini yaitu:


1. Hipotesis Nol (H_0): Tidak ada perbedaan signifikan pada rata-rata Skor Keseimbangan Makro (*macro_balance_score*) antara kategori makanan *Dish* dan *Component*. Proses pengolahan pangan tidak mengubah esensi keseimbangan distribusi gizi secara statistik.

$$\mu_{\text{Dish}} = \mu_{\text{Komponen}}$$

2. Hipotesis Alternatif (H_1): Terdapat perbedaan signifikan pada rata-rata Skor Keseimbangan Makro (*macro_balance_score*) antara kategori makanan *Dish* dan *Component*.

$$\mu_{\text{Dish}} \neq \mu_{\text{Komponen}}$$

```
=====
METRIK RINGKASAN STATISTIK SAMPEL A/B TESTING
=====
Grup A (Dish)      - Ukuran Sampel: 582 | Rata-rata Skor Keseimbangan: 0.7261
Grup B (Komponen) - Ukuran Sampel: 1052 | Rata-rata Skor Keseimbangan: 0.6840
-----
Hasil Nilai T-Statistic : 7.4232
Hasil Nilai P-Value      : 2.271641e-13
-----
Keputusan: TOLAK HIPOTESIS NOL (H0).
Kesimpulan: Terdapat perbedaan profil keseimbangan distribusi gizi makro
yang SIGNIFIKAN secara statistik antara hidangan siap saji (Dish)
dan bahan baku mentah (Component).
```



Berdasarkan visualisasi kurva sebaran data dan akumulasi nilai komputasi pada ringkasan statistik di atas, dilakukan analisis eksplanatori berlapis berikut.

1. Deskripsi Karakteristik Sampel

- Eksperimen melibatkan total 1.634 entri data bersih, yang terbagi atas 582 item berkategori Dish dan 1.052 item berkategori Component. Ukuran sampel yang besar ini memberikan tingkat kekuatan uji (*statistical power*) yang sangat tinggi untuk menghindari kesalahan penarikan kesimpulan tipe I maupun tipe II.
- Kelompok Dish menunjukkan nilai rata-rata *Macro Balance Score* sebesar 0.7261, mendahului kelompok Component yang tertahan di angka 0.6840. Terdapat selisih absolut nyata sebesar 0.0421 (atau setara dengan pergeseran positif sebesar 4.21% ke arah distribusi gizi seimbang).

2. Evaluasi Matematis terhadap Batas Nilai Kritis

Kekuatan pengujian statistik ini tecermin dari tingginya nilai penanda T-score yang mencapai 7.4232. Angka tersebut mencerminkan bahwa jarak antara pusat distribusi data kelompok *Dish* (hidangan olahan) dan kelompok *Component* (bahan pangan mentah) telah terpisah secara masif sejauh 7.4 kali standar deviasi, yang sekaligus menegaskan bahwa perbedaan karakteristik di antara kedua kelompok berada sangat jauh di luar batas variasi acak. Kondisi ini diperkuat oleh perolehan nilai P-Value yang sangat ekstrem, yaitu sebesar 2.271641×10^{-13} . Nilai peluang kesalahan yang menyentuh angka fraksi kuadriliun di bawah nol tersebut berada jauh

melampaui ambang batas alpha yang telah ditentukan ($\alpha = 0.05$). Mengingat probabilitas bahwa perbedaan rerata ini terjadi karena faktor kebetulan adalah hampir nol, sistem mengambil keputusan mutlak untuk menolak hipotesis 0 (H_0) dan menerima Hipotesis Alternatif (H_1).

3. Interpretasi Teknis

Keberhasilan penolakan hipotesis nol lewat A/B Testing ini memberikan landasan teori pangan yang sangat penting dalam melatarbelakangi logika kerja aplikasi GiSee. Hasil eksperimen membuktikan secara empiris teori bahwa bahan pangan tunggal atau mentah (komponen) secara alami memiliki struktur gizi yang kaku atau asimetris, di mana komoditas tersebut cenderung didominasi secara mutlak oleh satu zat gizi makro saja. Sebaliknya, proses pembuatan masakan jadi (*dish*) di Indonesia yang melibatkan pencampuran ragam bahan baku (seperti protein lauk, sayuran pengisi, bumbu padat, dan medium minyak/santan), sehingga mendorong nilai distribusi energinya bergeser secara signifikan menuju titik proporsi yang lebih bervariasi dan seimbang.

BAB VI

KESIMPULAN

Proyek ini berhasil membangun sebuah dataset pangan terintegrasi yang berasal dari dua sumber data berbeda, yaitu Tabel Komposisi Pangan Indonesia (TKPI) sebagai sumber data resmi pemerintah dan dataset publik Kaggle sebagai sumber data komunitas. Melalui rangkaian proses *data wrangling* yang meliputi *data gathering*, *data assessing*, *data cleaning*, standardisasi skema, deduplikasi berlapis, serta *feature engineering*, diperoleh dataset final `df_food` yang terdiri dari 1.634 makanan unik dengan struktur data yang konsisten dan siap digunakan untuk analisis nutrisi maupun pengembangan sistem berbasis kecerdasan buatan.

Tahap *assessing data* menunjukkan bahwa tantangan utama terdapat pada dataset TKPI, khususnya pada inkonsistensi tipe data, keberadaan nilai kosong pada beberapa kolom gizi makro, serta perbedaan struktur skema dengan dataset Kaggle. Seluruh permasalahan tersebut berhasil ditangani melalui proses konversi tipe data, imputasi nilai nol, normalisasi teks, dan penyelarasan nama kolom sehingga kedua dataset dapat digabungkan secara harmonis menjadi satu sumber data terpadu.

Setelah proses penggabungan selesai, dilakukan deduplikasi berlapis menggunakan kombinasi metode *exact matching* dan *fuzzy string matching* berbasis SequenceMatcher Similarity Ratio. Tahapan ini berhasil menghilangkan ratusan entri redundan yang berasal dari duplikasi nama makanan maupun variasi penulisan, sehingga kualitas dan integritas dataset meningkat secara signifikan.

Selain itu, proses *feature engineering* berhasil menghasilkan lima fitur turunan baru, yaitu *protein_per_calorie*, *fat_per_calorie*, *carb_per_calorie*, *protein_fat_ratio*, dan *macro_balance_score*. Fitur-fitur tersebut memberikan dimensi analisis yang lebih kaya dibandingkan hanya menggunakan nilai gizi dasar, karena mampu menggambarkan efisiensi protein, kepadatan energi, dominasi makronutrien, serta keseimbangan profil nutrisi suatu makanan.

Berdasarkan hasil *Exploratory Data Analysis* (EDA) dan Visualisasi, diperoleh beberapa temuan utama yang berhasil menjawab seluruh pertanyaan bisnis yang telah dirumuskan pada awal proyek, yaitu

1. Makanan dengan kandungan protein tertinggi didominasi oleh produk hewani yang mengalami proses pengeringan atau dehidrasi, seperti Kerupuk Kulit Kerbau (83,0 gram protein per 100 gram), Dendeng Mujair Goreng (74,3 gram), dan Ikan Kayu Kering (70,7 gram). Proses pengurangan kadar air terbukti meningkatkan konsentrasi protein secara signifikan.
2. Makanan dengan efisiensi protein tertinggi terhadap kalori didominasi oleh hidangan ikan tradisional berbasis kuah atau pengolahan rendah lemak. Jukku Pallu Kaloa Masakan menjadi makanan dengan rasio protein per kalori tertinggi, menunjukkan bahwa hidangan tersebut mampu menyediakan protein tinggi dengan beban energi yang sangat rendah.
3. Makanan dengan kepadatan energi tertinggi didominasi oleh kelompok minyak dan lemak murni. Opak Singkong tercatat sebagai makanan dengan kalori tertinggi dalam dataset (940 Kalori per 100 gram), diikuti berbagai jenis minyak dan lemak yang memiliki densitas energi mendekati batas teoritis tertinggi.
4. Lemak merupakan faktor yang paling memengaruhi total kalori makanan, dengan koefisien korelasi sebesar 0,754 terhadap kalori. Hasil ini membuktikan bahwa peningkatan kandungan lemak memberikan kontribusi terbesar terhadap kenaikan energi dibandingkan protein maupun karbohidrat.
5. Hidangan olahan (*dish*) memiliki profil nutrisi yang berbeda dibandingkan bahan pangan tunggal (komponen). Secara rata-rata, kategori dish memiliki kandungan kalori, lemak, dan karbohidrat yang lebih tinggi dibandingkan kategori komponen, sementara kandungan proteinnya relatif setara. Temuan ini menunjukkan bahwa proses pengolahan makanan berperan besar dalam meningkatkan kepadatan energi suatu makanan.

Secara keseluruhan, hasil analisis menunjukkan bahwa kombinasi data pangan resmi pemerintah dan data komunitas publik mampu menghasilkan basis data nutrisi yang komprehensif, representatif, dan kaya variasi untuk menggambarkan karakteristik pangan Indonesia.